

投稿CEUS文章审稿意见和修改建议

一、第一件必须解决的事：Fact / Question / Output / Explanation 到底如何进入模型

这是目前全文最需要先确认的问题。

你现在 Section 4.1.1 明确写：

serialized input includes Fact, Question, Output, and Explanation

MC 还会把 Selections 一起序列化。

随后给出的格式又是：

```
Fact
Question
Selections
The answer to the question is:
[output]
The reason for the answer is:
[explanation]
```

这会让 reviewer 产生一个非常严重的疑问：

模型预测答案的时候，是不是已经在输入中看到了 Output 和 Explanation?

如果答案是“是”，那现在所有 90%–100% 的准确率基本都不能作为有效实验结果。

正确的设计必须明确拆成 Prompt 和 Target

Multiple-choice

训练时：

代码块

```
1 INPUT / PROMPT:
2
3 Dataset context:
4 [Fact]
5
6 Question:
7 [Question]
8
```

```
9 Options:
10 A. ...
11 B. ...
12 C. ...
13 D. ...
14
15 Please provide the correct option and a concise explanation.
```

Target:

代码块

```
1 ANSWER:
2 B
3
4 EXPLANATION:
5 [Explanation]
```

推理时，模型**只能看到 INPUT / PROMPT**。

不能看到：

代码块

```
1 Output
2 Explanation
3 Ground-truth answer
```

Short-answer

Prompt:

代码块

```
1 Dataset context:
2 [Fact]
3
4 Question:
5 [Question]
6
7 Please provide a concise answer grounded in the dataset information.
```

Target:

代码块

```
1 ANSWER:  
2 [Ground-truth short answer]  
3  
4 EXPLANATION:  
5 [Ground-truth explanation]
```

这才是标准的：

$x = \text{Fact} + \text{Question} (+ \text{Options})$
 $y = \text{Answer} + \text{Explanation}$

模型学习：

$P(y \mid x)$

而不是：

$P(y \mid x, y)$

对 LLaMA/Qwen 和 T5 还要分别写清楚

对于 **decoder-only models**，例如 LLaMA/Qwen，训练过程中实现上可以把 prompt 与 target 拼在同一个 token sequence：

代码块

```
1 [PROMPT] [TARGET]
```

但关键是：

prompt tokens 必须 mask 掉，不参与 target loss；loss 只计算 target tokens。

论文里可以写成：

For decoder-only models, the prompt and target are concatenated during supervised fine-tuning for implementation convenience. However, loss is computed exclusively over target tokens, whereas all prompt tokens are masked. At inference time, only the prompt is provided to the model.

对于 **T5**：

Encoder：

代码块

Decoder target:

代码块

1 Answer + Explanation

这样才公平。

所以你现在首先检查代码

如果你的实际代码本来就是这样，只是论文描述错了：

不用重跑实验，只改 Method。

这是最好的情况。

如果你的 actual inference prompt 确实包含 Output/Explanation：

Tables 3-5、Fig. 4，以及 France/Japan evaluation 全部需要重新跑。

这一点没有文字修饰可以绕过去。

而且不要害怕重新跑以后 100% 变成 82%、88%、91%。

对于 CEUS 来说：

可信的 85% 比存在 leakage 风险的 100% 强得多。

二、第二个必须解决：22,000 条数据不能 augmentation 完再随机 80:20

目前 Method 写的是先生成大量 GPT-5.1 augmented variants，得到 22,000 条。

然后：

The full dataset is randomly divided into training and testing subsets using an 80:20 split.

这对于你这种数据构造方式风险很大。

假设原始 seed 是：

What is the temporal resolution of dataset X?

GPT augmentation 得到：

A

At what temporal resolution was dataset X collected?

B

| What is the sampling interval of dataset X?

C

| How frequently are observations recorded in dataset X?

如果 A 在 train、B 在 test：

这不能很好证明模型 “generalize 到 unseen reasoning task” 。

它可能只是：

| 训练集语义近邻 → 测试集语义近邻。

正确 protocol：Split BEFORE Augmentation

建议给每个人工/curated seed 一个唯一：

代码块


```
1 seed_id
```

例如：

代码块

```
1 highD_L1_temporal_SA_001
2 highD_L1_spatial_MC_002
3 TLC_L2_spatiotemporal_SA_003
```

然后流程必须变成：



```
12 Augmentation Augmentation Augmentation
13     ↓           ↓           ↓
14 Train set      Validation    Test set
```

而不是：

代码块

```
1 Seeds
2 ↓
3 GPT augmentation
4 ↓
5 22,000 samples
6 ↓
7 random split ← 这个要取消
```

三、具体怎么 split

我建议不要执着保持“80/20”这个数字。

更规范的是：

Train / Validation / Test = 80 / 10 / 10

但真正重要的不是比例，而是：

同一个 seed_id 的所有 descendants 永远只能属于一个 split。

包括：

- original version
- paraphrased versions
- positive instance
- negative instance
- MC variants
- option reordered versions

全部必须跟随 seed group。

例如：

代码块

```
1 seed_001
```

```
2  |— positive_001
3  |— positive_002
4  |— positive_003
5  |— negative_001
6  |— negative_002
7  └— negative_003
```

这整个 family 要么全部 train:

代码块

```
1  seed_001 → TRAIN
```

要么全部 test:

代码块

```
1  seed_001 → TEST
```

绝对不能拆开。

同时进行 stratification

划分的时候至少保持:

代码块

```
1  Data source
2  Difficulty level
3  Task type
```

尽量平衡。

也就是:

同时保证 L1/L2/L3 和 SA/MC 尽可能都有代表性。

但你现在 Level 3 seed 数量似乎比较少，所以**不要机械追求 80/10/10**。应该根据实际 unique seed 数量设计，核心原则是 **group isolation**。

四、Method 中这部分可以改成这样的逻辑

你最后可以写：

To prevent semantic leakage between augmented variants, data partitioning was performed at the seed-instruction level before augmentation. Each curated seed instruction was assigned exclusively to the training, validation, or test partition, and all augmented variants derived from the same seed inherited the same partition label. The split was stratified with respect to data source, reasoning level, and task type whenever possible. Consequently, no augmented paraphrases or positive-negative variants originating from the same seed appeared across different partitions.

然后再补一句：

Exact and near-duplicate samples across partitions were additionally screened before model training and evaluation.

这一句最好真的去做。

五、建议增加一个非常低成本但很值钱的 leakage audit

这不是“增加一个模型实验”。

只是数据质量检查。

至少检查：

Exact duplicate

以及：

near duplicate

比如 normalized text similarity 或 embedding similarity。

然后在 Supplementary Material 给一个小表：

Check	Train-Val	Train-Test	Val-Test	TLC	Urban Flow
Exact duplicates	0	0	0	✓	✓
Same seed family	0	0	0	✓	✓
High-similarity near duplicates	...	...	...	✓	✓

这个表对 CEUS reviewer 非常有用。

六、第三个我认为与前两个一样严重的问题：Negative examples

你现在写：

positive example：

| correct output

negative example：

| intentionally incorrect output

而且 positive/negative 被作为 paired supervision。

这里 reviewer 会问：

| 既然是普通 supervised fine-tuning，为什么模型要学习一个“错误 target”？

如果你的训练方式是：

代码块

1 Question → WRONG ANSWER

然后这个 wrong answer 也进入 SFT loss：

这是有问题的。

最推荐的处理方法

既然你反正大概率要重新 split/retrain，我建议把负样本改成 **answer verification task**。

正例：

代码块

```
1 Fact:
2 ...
3
4 Question:
5 ...
6
7 Candidate answer:
8 [correct answer]
9
10 Is this answer consistent with the dataset?
```

Target:

代码块

```
1 Correct.
2
3 Explanation:
4 ...
```

负例:

代码块

```
1 Fact:
2 ...
3
4 Question:
5 ...
6
7 Candidate answer:
8 [incorrect but plausible answer]
9
10 Is this answer consistent with the dataset?
```

Target:

代码块

```
1 Incorrect.
2
3 Correct answer:
4 ...
5
6 Explanation:
```

这样你的 positive/negative supervision 就变得非常合理：

| 模型不仅学习生成正确答案，还学习识别 plausible but incorrect urban-data interpretations。

这反而比你现在的写法强。

可以把它叫：

| **generation-verification instruction framework**

而不要轻易叫 “contrastive learning”，除非你真的使用了 contrastive loss、ranking loss 或 DPO。

七、如果你完全不想改变训练 task

还有一个更简单的方案：

Positive instances：用于 SFT

Negative instances：只作为 hard negatives / robustness evaluation

这样不要再写：

| contrastive supervision

而写：

| plausible negative instances for robustness assessment.

这是修改量更小的路线。

但从论文创新性来说，我更推荐前面的 **generation + verification**。

八、你现在还有一个非常重要的 cross-regional 表述问题

你的论文写：

| models trained on U.S.-centric datasets transfer to France and Japan.

但你自己的 Reference [10] 写得很清楚：

| highD 是 **German Highways** 数据。

所以：

| “U.S.-centric → France/Japan” 这个 narrative 不准确。

不要继续使用。

改为：

training-source datasets → geographically held-out datasets from France and Japan

或者：

cross-regional transfer to held-out transportation datasets from France and Japan

你的贡献仍然成立，而且更严谨。

我甚至建议全文不要再叫：

cross-city generalization

而主要叫：

cross-regional dataset transfer

因为 highD、NGSIM、Road Networks、TLC 本身并不都是同类型的 “city dataset”。

九、CEUS 版本的 Title 必须改

现在：

LLM Empowering Urban Science: The Exploration of Constructing a New Instruction Dataset

太宽、太弱，而且 “Exploration of Constructing a New...” 很不像一篇成熟期刊论文。

我优先考虑：

方案 A——我最推荐

Dataset-Grounded Instruction Tuning for Transferable Urban-Data Reasoning with Large Language Models

方案 B——强调研究问题

Can Large Language Models Learn Transferable Urban-Data Reasoning? A Dataset-Grounded Instruction-Tuning Framework

方案 C——强调 heterogeneous data

Learning to Reason over Heterogeneous Urban Data: A Dataset-Grounded Instruction-Tuning Framework for Large Language Models

我目前最喜欢 C。

因为它非常贴近 CEUS：urban data + heterogeneity + computational methodology。

CEUS 官方本身强调 computer-based research 对 urban systems 的理解，并突出 spatial/geospatial perspective。

十、Abstract 要彻底重写逻辑

现在 Abstract 很大部分是在报告：

Qwen near-perfect

LLaMA gains

T5 behavior。

这比较像 NLP benchmark。

CEUS Abstract 推荐按照：

Urban problem → Research gap → Method → Evaluation → Main finding → Urban implication

写。

不要以：

| LLMs are powerful...

开始。

而可以从：

| Urban analytics increasingly relies on heterogeneous mobility, infrastructure, and network datasets whose differing schemas, spatial scales, and measurement conventions create substantial barriers to automated interpretation.

开始。

然后提出：

| general-purpose LLMs lack systematic grounding in the structure and semantics of urban datasets.

然后才进入：

| We develop...

最后不要以：

| Qwen is best / LLaMA improves...

作为最大 conclusion。

应该变成：

| Results indicate that dataset-grounded supervision improves transferable urban-data interpretation, but the benefits depend strongly on model architecture and output-control behavior.

最后：

This highlights both the opportunities and limitations of LLM-based interfaces for heterogeneous urban data systems.

模型名是 evidence，不是论文主题。

十一、Introduction 建议重新组织成 5 段，而不是现在的逻辑

你现在从 urban planning、IoT、LLMs、RAG、multi-agent、domain-specific LLM 一路展开。

内容很多，但 research question 不够聚焦。

Paragraph 1: Urban-data problem

核心不是 LLM。

而是：

modern urban analysis depends on heterogeneous data.

highD: microscopic trajectory

NGSIM: vehicle trajectory

Road network: graph/infrastructure

TLC: mobility demand

France/Japan: different institutional/geographic systems

强调：

spatial scale、temporal scale、schema、semantics、measurement conventions 不统一。

Paragraph 2: 为什么现有 AI/LLM 不够

general LLM 有语言能力，

但：

knowing text $\neq$ understanding an urban dataset.

尤其要区分：

- dataset provenance
- spatial coverage
- temporal resolution
- variable semantics

- analytical applicability
 - limitations
-

Paragraph 3: 最近 CEUS / urban LLM literature

这一段一定加之前查到的 CEUS 近两年论文。

尤其 Zhao et al. 2025 在 CEUS 已经使用 556-task benchmark 系统评价 LLM 的 urban-planning 能力。

所以不要再说：

“There are no urban LLM benchmarks.”

应该改成：

Existing work has increasingly evaluated general-purpose LLMs on urban-planning and urban-analytics tasks, but comparatively less attention has been paid to constructing dataset-grounded supervision for adapting open models to heterogeneous urban data.

这个 gap 更安全。

Paragraph 4: 真正的 research gap

把 gap 浓缩成三个问题：

RQ1: How can heterogeneous urban datasets be systematically transformed into grounded instruction supervision?

RQ2: Does such supervision improve dataset-grounded reasoning across different model architectures and reasoning levels?

RQ3: To what extent can learned reasoning transfer to geographically and institutionally different urban datasets?

这三个就是你的全文主线。

Paragraph 5: Contributions

贡献不要再写成：

We made a QA dataset.

而应该是：

Contribution 1 — Dataset-grounded urban instruction framework

Contribution 2 — Hierarchical urban-data reasoning taxonomy

这样档次高很多。

十二、Related Work：删掉大部分“LLM 教科书”

现在 2.1 花很多文字介绍：

BERT

T5

GPT

LLaMA

Qwen。

对于 CEUS reviewer，没有必要。

建议改成：

2.1 AI and Large Language Models for Urban Analytics

CEUS / urban computing 文献。

2.2 Domain Adaptation and Instruction Tuning

这里再简要介绍：

FLAN

Self-Instruct

instruction tuning

domain adaptation。

BERT/T5/LLaMA architecture 最多一小段。

2.3 Dataset-Grounded Reasoning over Urban Data

这是最重要的小节。

最后必须落到：

Existing studies primarily evaluate LLMs as general-purpose inference engines or apply them to specific urban tasks, whereas systematic mechanisms for transforming heterogeneous urban datasets into reusable domain-grounded supervision remain less explored.

你的 novelty 就在这里。

十三、Method 的内部矛盾必须全部清掉

目前这一部分的问题其实很多。

1. Four-stage vs five-stage

Contribution 写：

| four-stage pipeline。

Method 写：

| five core steps。

统一成一个版本。

我建议五阶段：

代码块

- 1 1 Urban-data grounding
- 2 2 Seed instruction design
- 3 3 Hierarchical task construction
- 4 4 Positive/negative generation or verification
- 5 5 Augmentation and quality control

Split 不属于数据构建 pipeline，单独放 Evaluation Protocol。

2. Level 1 数量错误

你写：

| ten key perspectives

但实际只列了九个。

必须核对实际代码/数据。

不要简单“补一个名字”凑成 10 个。

要依据你真实数据。

3. Level 2 seed 数量矛盾

你说：

| five combinations

然后每个组合生成 short-answer + multiple-choice，

逻辑上应该 10 个 instances，

但下一句又写：

| five Level 2 seeds per dataset。

必须根据实际 construction code 修正。

十四、强烈建议重新设计 Table 1

现在 Table 1 主要是：

| 3000 / 1000 / 1000 / SA / MC / Total。

对 CEUS 来说信息量不够。

我建议第一张重要表变成：

Source	Urban domain	Geography	Spatial scale	Temporal scale	Data structure	L1
highD	Highway mobility	Germany	Trajectory	Sub-second	Tabular trajectory	✓
NGSIM	Traffic dynamics	...	...	...	...	✓
TLC	Urban mobility	NYC	Zone/trip	Trip-level	Trip records	✓
...						

这里所有具体信息必须依据真实 dataset documentation 填，不能凭印象。

这个表会一下子把你的论文从：

| “五个 NLP sources”

变成：

| multiscale heterogeneous urban-data study

非常符合 CEUS 的视角。

十五、Fig. 1 建议删掉当前 pie chart

目前 Fig.1 只是显示 SA/MC 和 Level1/2/3 比例。

对一篇竞争激烈的 CEUS 文章而言，这张图占正文版面价值不高。

更值得画的是：

heterogeneous urban datasets → data grounding → hierarchical reasoning → seed-level split → augmentation → model adaptation → in-domain + regional transfer

而且一定要在图里面画出：

代码块

```
1 SPLIT BEFORE AUGMENTATION
```

这样 reviewer 一眼就看到你解决了 leakage。

现有 pie chart 可以放 Supplement。

十六、模型设置现在也有明显矛盾

Section 4.1.2 写：

LLaMA, BERT, and Qwen

并声称：

three different model sizes per family。

但实际 Results 是：

- T5-base
- Qwen2.5-7B
- Qwen2.5-14B
- LLaMA3-8B
- LLaMA3-70B

没有 BERT。

这个必须彻底统一。

建议不要为了“架构完整”硬保留 BERT。

真实做了什么就写什么：

encoder-decoder: T5

decoder-only: LLaMA3

decoder-only instruction-oriented: Qwen2.5

然后解释为什么选择它们。

十七、Evaluation metrics 我建议也修改，不需要增加模型

现在 MC 里一个非常明显的问题是：

T5 输出了正确文字，

但是没有输出：

代码块

```
1 A/B/C/D
```

结果记成 0%。你自己后文也承认这一点。

这其实不是：

| 0% reasoning accuracy

而是：

| format failure。

所以建议把 MC 拆成三个指标。

① Strict MC Accuracy

必须严格输出 A/B/C/D。

② Normalized Answer Accuracy

如果模型输出：

| “The correct answer is road connectivity.”

而对应 option 是 B，

经过 deterministic parser 映射为 B 后，也算正确。

③ Format Compliance Rate

是否按照要求输出：

代码块

```
1 B
```

这会把：

| semantic correctness

和：

| structured output compliance

分开。

这正好还能强化你目前 Discussion 里发现的 format overfitting / output drift。

非常值得做。

而且如果你保存了现有 prediction：

| 只需要重新 scoring，不需要重新训练。

十八、BERTScore / ROUGE 也不要作为“reasoning”的直接证明

你现在的 metrics 主要是：

ROUGE

BERTScore

classification accuracy。

对于 SA，可以保留。

但是结论不要写：

| higher BERTScore = stronger reasoning.

更准确：

| higher semantic agreement with reference responses.

然后真正的 reasoning claims 应主要由：

- L2/L3 performance
- held-out seeds
- cross-regional transfer
- correctness

支持。

十九、Results 整节建议改成 Research Questions

你现在 5.3、5.4、5.5 里面大量重复：

Qwen 稳定

LLaMA gain 大

T5 格式不好。

建议直接改成：

5.1 RQ1: Does dataset-grounded instruction tuning improve urban-data reasoning?

Pre vs Post。

5.2 RQ2: How do architecture and model scale affect adaptation?

LLaMA vs Qwen vs T5。

5.3 RQ3: How does performance vary across reasoning levels?

L1 → L2 → L3。

5.4 RQ4: Does the learned capability transfer across geographic contexts?

France / Japan。

5.5 What failures emerge from structured urban-data instruction tuning?

format compliance

verbosity

overgeneration

failure cases。

这样文章立刻从：

| ML benchmark report

变成：

| empirical urban-computing study。

二十、France/Japan 要从附加实验升级为主贡献

你现在 France 和 Japan 放到 Section 5.6 才出现。

实际上这可能是你 CEUS 版本最有价值的实验之一。

建议 Abstract 就说：

| geographic transfer

Introduction RQ3 说：

| geographically held-out urban datasets

Method 专门一节：

| Cross-regional evaluation protocol

Results 专门 RQ4。

Discussion 再谈：

| geographic context、institutional schema、transportation-data interoperability。

这非常符合 CEUS 对 spatial scope 和 urban-system dynamics 的关注。

二十一、“Reason as urban planners do” 建议降调

目前 Method 写：

| teach models to reason as urban planners do。

我不建议保留。

因为你没有 planner evaluation，也没有真实 planning decision experiment。

改成：

| acquire dataset-grounded reasoning patterns relevant to urban analysis

或者：

| support foundational reasoning over urban-data properties and analytical constraints.

同理：

| planning cognition

也尽量少使用。

你的论文真正证明的是：

| **urban-data reasoning**

而不是：

| **human planner cognition**

减少 claim 反而更容易过审。

二十二、一个非常严重的数据来源问题也必须解决

你现在把：

| Urban Flow Prediction Survey

当成五个 source datasets 之一。

但 Reference [14] 实际是：

| *The optimal traffic enforcement strategy under a budget constraint...*

完全不是同一东西。

必须先回答：

| “Urban Flow Prediction Survey” 到底是什么？

如果是一个真实 dataset：

必须给：

- official name
- source
- URL/DOI
- version
- documentation

如果其实是一篇 survey paper：

就不能叫：

| dataset。

应该叫：

| literature-derived knowledge source

这样你的五来源结构甚至可能要改成：

| four empirical datasets + one literature-derived source。

这一点在投稿前必须解决。

二十三、References 必须做一次彻底 audit

比如 Reference [67]：

| arXiv:2404.XXXX

肯定不能这样投稿。

另外：

| Author(s) not provided

这种也必须清理。

建议逐条核查：

DOI

title

authors

venue

year

published version

citation relation。

并优先补 CEUS 近两年的 LLM × urban analytics literature。特别是 Zhao et al. 2025 已经直接构建了 urban-planning LLM benchmark，所以你的 novelty 不能写成泛泛的“缺少 urban benchmark”。

二十四、Discussion 不要再主要讨论“哪个模型好”

CEUS 版 Discussion 应该回答：

Urban-data interoperability

为什么异构 schema 会影响 LLM？

Geographic transfer

为什么某些 dataset-grounded knowledge 可以迁移？

哪些不能迁移？

Spatial/temporal semantics

LLM 是否真正理解：

spatial granularity

temporal resolution

network structure

mobility scale？

Deployment implications

semantic correctness $\neq$ reliable urban analysis。

Dataset design implications

为什么 structured instruction 会导致：

format overfitting

verbosity

output drift?

你目前已经观察到这些现象。

所以不需要新增实验，就可以把 Discussion 提升不少。

二十五、Limitations 反而应该写得更诚实

我建议明确承认：

当前任务主要基于 dataset metadata/documentation，而不是直接对 raw trajectories / spatial networks 做 numerical inference。

这是非常重要的。

否则 reviewer 很容易说：

“Your model is reasoning over textual descriptions of urban data, not over urban data themselves.”

你的回答应该提前写出来：

本文关注的是 **foundational data understanding layer**，即数据 provenance、structure、spatial-temporal properties、applicability 和 limitations，这是更复杂 forecasting/simulation/decision tasks 的前置能力。

这样 scope 就合理很多。

二十六、我建议最终重构成这样的文章

1. Introduction

urban-data heterogeneity → LLM opportunity → grounding gap → RQs。

2. Related Work

2.1 LLMs for urban analytics

2.2 Domain adaptation and instruction tuning

2.3 Dataset-grounded urban-data reasoning

3. Dataset-Grounded Instruction Framework

3.1 Heterogeneous urban-data sources

3.2 Hierarchical reasoning taxonomy

3.3 Instruction schema

3.4 Positive/negative or verification design

3.5 Augmentation and quality control

4. Leakage-Free Evaluation Protocol

4.1 Seed-level split before augmentation

4.2 Prompt–target separation

4.3 Models and training

4.4 Metrics

4.5 Cross-regional evaluation

5. Results

5.1 RQ1 Adaptation effectiveness

5.2 RQ2 Architecture differences

5.3 RQ3 Reasoning complexity

5.4 RQ4 Geographic transfer

5.5 Failure analysis

6. Discussion

urban implications + transferability + model behavior。

7. Limitations

8. Conclusion

这个结构比你当前版本明显更适合 CEUS。